

ÁLGEBRA LINEAR PARA DATA SCIENCE E MACHINE LEARNING



CONTEÚDO DO CURSO

- Definição – equação linear
- Escalares, vetores, matrizes, tensores
- Sistemas lineares
- Vetores
- Matrizes
- Operações
- Transformações
- Aplicações



NumPy

DEFINIÇÃO

- **Álgebra linear** é uma subárea da **Álgebra**
- A **Álgebra** trata de problemas matemáticos envolvendo **variáveis**

The diagram illustrates the components of algebraic equations. It lists three equations: $x + 2 = 5$, $4x - \frac{1}{2}y^2 = 1$, and $7x + \sqrt{5}y^2 - \frac{1}{3}\log z = 10$. An orange speech bubble labeled 'variáveis' points to the variables x , y , and z in the equations. A blue speech bubble labeled 'constantes' points to the constants 2 , $\frac{1}{2}$, $\sqrt{5}$, $\frac{1}{3}$, and 10 . A large blue bracket on the right groups the equations under the label 'equações'.

$$\left. \begin{array}{l} x + 2 = 5 \\ 4x - \frac{1}{2}y^2 = 1 \\ 7x + \sqrt{5}y^2 - \frac{1}{3}\log z = 10 \end{array} \right\} \text{equações}$$

- Objetivo da Álgebra é encontrar os valores das variáveis → **resolver as equações**

DEFINIÇÃO

- **Álgebra linear** trata de problemas matemáticos envolvendo **variáveis lineares**

✓ $x + 2 = 5$

✗ $4x - \frac{1}{2}y^2 = 1$

✗ $7x + \sqrt{5}y^2 - \frac{1}{3}\log z = 10$

✓ $4x - \frac{1}{2}y = 1$

✓ $7x + \sqrt{5}y - \frac{1}{3}z = 10$

- **Equações lineares** podem ser representadas como **retas** (linhas)

EQUAÇÃO LINEAR

$$4x - \frac{1}{2}y = 1$$




$$-\frac{1}{2}y = -4x + 1$$



$$y = 8x - 2 = f(x)$$



equação de uma reta



EQUAÇÃO LINEAR


variável dependente
variável independente

$$y = ax + b$$

coeficiente angular
coeficiente linear (intercepto)

$$y = 8x - 2$$

coeficiente linear \rightarrow



EQUAÇÃO LINEAR

- Equações lineares com mais de uma variável independente

$$y = a_1x_1 + a_2x_2 + a_3x_3 + \cdots + a_nx_n + b$$

$a_1, a_2, a_3, \dots, a_n \rightarrow$

coeficientes angulares de cada variável $x_1, x_2, x_3, \dots, x_n$

$b \rightarrow$ coeficiente linear da reta

EQUAÇÃO LINEAR

$$y = 7.5x_1 + 8.25x_2 + 35.8x_3 + 15x_4 + 10$$

$b = \text{R\$ } 10 = \text{couvert artístico}$

$a_4 = \text{R\$ } 15 = \text{preço da sobremesa}$

$x_4 = \text{quantidade de sobremesas}$

$a_3 = \text{R\$ } 35.80 = \text{preço do prato principal}$

$x_3 = \text{quantidade de pratos principais}$

$a_2 = \text{R\$ } 8.25 = \text{preço da entrada}$

$x_2 = \text{quantidade de entradas}$

$a_1 = \text{R\$ } 7.50 = \text{preço da bebida}$

$x_1 = \text{quantidade de bebidas}$

DESPESA TOTAL

ESCALARES, VETORES, MATRIZES, TENSORES

• Escalares

$$y = \boxed{7.5}x_1 + \boxed{8.25}x_2 + \boxed{35.8}x_3 + \boxed{15}x_4 + \boxed{10}$$

$$x + 2 = 5$$

float

integer

$$4x - \frac{1}{2}y = 1$$

$$7x + \sqrt{5}y - \frac{1}{3}z = 10$$

ESCALARES, VETORES, MATRIZES, TENSORES

• Vetores

Row:


[7.5, 8.25, 35.8, 15, 10] *array*

ndarray 1-D

Column:

[7.5, → x_1
8.25, → x_2
35.8, → x_3
15, → x_4
10] → x_5

Notação:
 v, \vec{v}



ESCALARES, VETORES, MATRIZES, TENSORES

• Matrizes

$$\begin{bmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \dots & a_{mn} \end{bmatrix}$$

array de array

ndarray 2-D

$$\begin{bmatrix} [a_{11}, a_{12}, \dots, a_{1n}], \\ [a_{21}, a_{22}, \dots, a_{2n}], \\ \dots \\ [a_{m1}, a_{m2}, \dots, a_{mn}] \end{bmatrix}$$

Forma genérica dos elementos de uma matriz: a_{ij}


Notação:

A

ESCALARES, VETORES, MATRIZES, TENSORES

• Tensores

Objeto matemático	ÁLGEBRA	PYTHON (NumPy) ndarray np.array	PYTHON (TensorFlow/PyTorch) tensor
Escalar	Tensor de rank = 0	Array de ndim = 0	Tensor de ndim = 0
Vetor	Tensor de rank = 1	Array de ndim = 1	Tensor de ndim = 1
Matriz	Tensor de rank = 2	Array de ndim = 2	Tensor de ndim = 2
“Tensor”	Tensor de rank ≥ 3	Array de ndim ≥ 3	Tensor de ndim ≥ 3



método numpy

TENSORES EM ÁLGEBRA LINEAR

Sistemas lineares

$$y = 7.5x_1 + 8.25x_2 + 35.8x_3 + 15x_4 + 10$$

$$a_1x_1 \begin{cases} a_1 = \text{preço} \\ x_1 = \text{quantidade} \end{cases} \Updownarrow \begin{cases} a_1 = \text{quantidade} \\ x_1 = \text{preço} \end{cases}$$

$$\begin{cases} 127.35 = x_1 + x_2 + 2x_3 + 2x_4 + 10 \\ 128.10 = 2x_1 + 2x_2 + 2x_3 + x_4 + 10 \\ 134.85 = 2x_1 + x_2 + 2x_3 + 2x_4 + 10 \\ 119.85 = 2x_1 + x_2 + 2x_3 + x_4 + 10 \end{cases}$$

$$\begin{bmatrix} 127.35 \\ 128.10 \\ 134.85 \\ 119.85 \end{bmatrix} = \begin{bmatrix} 1 & 1 & 2 & 2 \\ 2 & 2 & 2 & 1 \\ 2 & 1 & 2 & 2 \\ 2 & 1 & 2 & 1 \end{bmatrix} \times \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} + \begin{bmatrix} 10 \\ 10 \\ 10 \\ 10 \end{bmatrix}$$

- sistema linear
- uma solução (completo, não-singular)
 - nenhuma solução (singular)
 - infinitas soluções (singular)
 - ~~mais que uma solução?~~

→ $y = Ax + b$




TENSORES EM ÁLGEBRA LINEAR

Sistemas lineares

Introdução



$$\begin{cases} 127.35 = x_1 + x_2 + 2x_3 + 2x_4 + 10 & \text{casal_1} \\ 128.10 = 2x_1 + 2x_2 + 2x_3 + x_4 + 10 & \text{casal_2} \\ 134.85 = 2x_1 + x_2 + 2x_3 + 2x_4 + 10 \\ 119.85 = 2x_1 + x_2 + 2x_3 + x_4 + 10 \end{cases}$$



TENSORES EM MACHINE LEARNING

Representação de dados

Introdução

Dados tabulares (Pandas → DataFrame)

	Número de bebidas	Número de entradas	Número de pratos principais	Número de sobremesas	Valor total de couvert	Valor da conta
casal_1	1	1	2	2	10	127.35
casal_2	2	2	2	1	10	128.10
casal_3	2	1	2	2	10	134.85
casal_4	2	1	2	1	10	119.85

Arrays (NumPy → ndarray)



atributo values

```
[[1, 1, 2, 2, 10, 127.35],  
 [2, 2, 2, 1, 10, 128.10],  
 [2, 1, 2, 2, 10, 134.85],  
 [2, 1, 2, 1, 10, 119.85]]
```

X

y



```
[[1, 1, 2, 2, 10, 127.35]]
```

1×6

instância

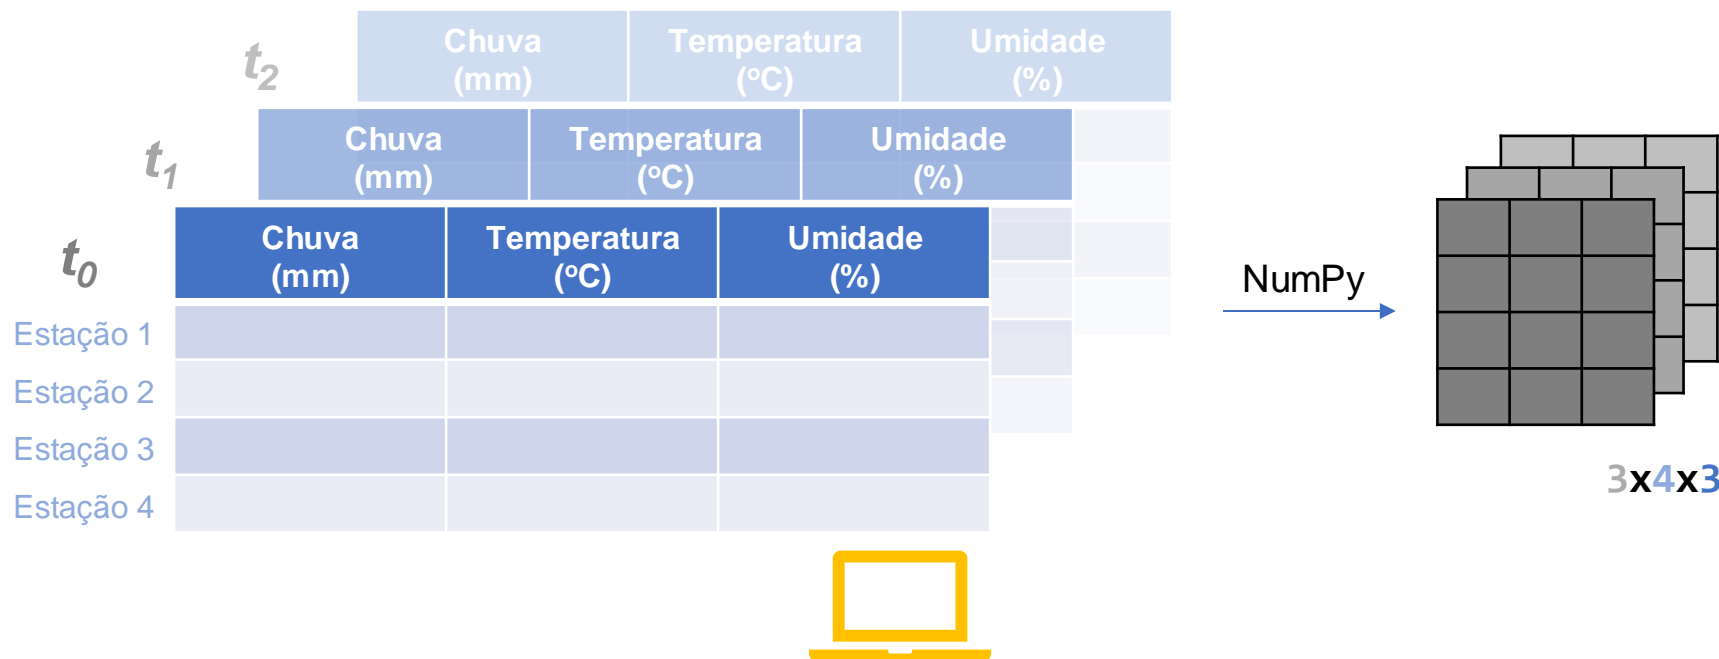


TENSORES EM MACHINE LEARNING

Representação de dados

Introdução

Séries temporais





TENSORES EM MACHINE LEARNING

Representação de dados

Introdução

Imagens



$[1, h, c]$

$[b, 1, h, c]$

NumPy


```
[  
  [  
    [11r, 12r, 13r, ...],  
    [21r, 22r, 23r, ...],  
    ...  
  ],  
  [  
    [11g, 12g, 13g, ...],  
    [21g, 22g, 23g, ...],  
    ...  
  ],  
  [  
    [11b, 12b, 13b, ...],  
    [21b, 22b, 23b, ...],  
    ...  
  ]  
]
```



TENSORES EM MACHINE LEARNING

Representação de dados

Embeddings




TENSORES EM MACHINE LEARNING

Estrutura de redes neurais

Introdução

Pesos e bias de redes neurais



$$W = \begin{bmatrix} [w_{11}, w_{12}], \\ [w_{21}, w_{22}], \\ [w_{31}, w_{32}] \end{bmatrix}$$


$$b = [b_{11}, b_{12}]$$



APLICAÇÕES EM MACHINE LEARNING

- **Treinamento de algoritmos**
- Redução de dimensionalidade
- Processamento de imagens
- Ranqueamento de resultados
- Sistemas de recomendação
- Processamento de linguagem natural

$$\begin{cases} 127.35 = x_1 + x_2 + 2x_3 + 2x_4 + 10 \\ 128.10 = 2x_1 + 2x_2 + 2x_3 + x_4 + 10 \\ 134.85 = 2x_1 + x_2 + 2x_3 + 2x_4 + 10 \\ 119.85 = 2x_1 + x_2 + 2x_3 + x_4 + 10 \end{cases}$$



ÁLGEBRA LINEAR

Vetores

DEFINIÇÃO (revisão)


Row:

[7.5, 8.25, 35.8, 15, 10]

Column:

[7.5, $\rightarrow x_1$
8.25, $\rightarrow x_2$
35.8, $\rightarrow x_3$
15, $\rightarrow x_4$
10] $\rightarrow x_5$

Notação:
 v, \vec{v}



Álgebra: tensor de rank 1

Python:

- NumPy: ndarray (1-D)
- TF/PyTorch: tensor (1-D)

NORMAS


- Normas: funções que caracterizam o vetor
 - *Norma L1 (L1-norm)*: soma das coordenadas absolutas

$$\|x\|_1 = \sum_i |x_i|$$

$$\|x\|_1 = |x_1| + |x_2|$$

$$\|x\|_1 = 7.5 + 8.25$$

$$\|x\|_1 = 15.75$$



NORMAS


- Normas: funções que caracterizam o vetor
 - *Norma L2 (L2-norm)*: comprimento do vetor

$$\|x\|_2 = \sqrt{\sum_i x_i^2}$$

$$\|x\| = \sqrt{x_1^2 + x_2^2}$$

$$\|x\| = \sqrt{7.5^2 + 8.25^2}$$

$$\|x\| = 11.149$$



NORMAS

- Normas L1 e L2 são usadas para **regularizar** funções de custo.
- **Regressão linear:**

$$y = Ax + b \rightarrow RSS = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- **Regressão lasso (L1)**

$$RSS = \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \alpha \|A\|_1$$

- Remove correlações (zera alguns coeficientes) \rightarrow **seleção de atributos**


- **Regressão ridge (L2)**

$$RSS = \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \alpha \|A\|_2$$

- Coeficientes menores (próximos de zero)


VETOR UNITÁRIO E BASE

- **Vetor unitário:** vetor cujo comprimento (L2-norm) é igual a 1.
- **Vetor base:** vetor unitário que reside nos eixos do sistema cartesiano.



VETOR TRANSPOSTO

- Vetor transposto:** vetor linha transformado em vetor coluna, ou vice-versa.



$$\vec{x} = [7.5 \quad 8.25] \quad \Rightarrow \quad \vec{x}^T = \begin{bmatrix} 7.5 \\ 8.25 \end{bmatrix}$$


$$\vec{x} = [[7.5 \quad 8.25]]_{1 \times 2} \quad \Rightarrow \quad \vec{x}^T = \begin{bmatrix} [7.5] \\ [8.25] \end{bmatrix}_{2 \times 1}$$

$$\hat{i} = [1 \quad 0] \quad \Rightarrow \quad \hat{i}^T = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

$$\hat{j} = [0 \quad 1] \quad \Rightarrow \quad \hat{j}^T = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$

VETOR ORTOGONAL E ORTONORMAL

- **Vetores ortogonais:** vetores que mantêm 90 graus entre si.
- **Vetores ortonormais:** vetores ortogonais e também unitários.



$$\begin{aligned}\vec{y} &\neq f(\vec{x}) \\ \vec{x} &\neq f(\vec{y}) \\ \hat{j} &\neq f(\hat{i}) \\ \hat{i} &\neq f(\hat{j})\end{aligned}$$

$$\vec{x} \cdot \vec{y} = 0$$

	\vec{b}	\vec{e}	\vec{p}	\vec{s}		
	Número de bebidas	Número de entradas	Número de pratos principais	Número de sobremesas	Valor total de couvert	Valor da conta
casal_1	1	1	2	2	10	127.35
casal_2	2	2	2	1	10	128.10
casal_3	2	1	2	2	10	134.85
casal_4	2	1	2	1	10	119.85


ÁLGEBRA LINEAR

Matrizes

DEFINIÇÃO (revisão)

• Matrizes

$$\begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix}$$



Forma genérica dos elementos de uma matriz: a_{ij}

Álgebra: tensor de rank 2

Computação: array de array

Python (NumPy): ndarray (2-D)

NORMAS

Norma Frobenius:

$$\|\mathbf{X}\|_F = \sqrt{\sum_{i,j} x_{i,j}^2}$$

Norma L2 do vetor

$$\|\mathbf{x}\|_2 = \sqrt{\sum_i x_i^2}$$

- análoga à norma L2 do vetor
- medida de “tamanho” (distância euclidiana)

Item do cardápio

```
[ [1, 1, 2, 2, 10, 127.35], casal
  [2, 2, 2, 1, 10, 128.10],
  [2, 1, 2, 2, 10, 134.85],
  [2, 1, 2, 1, 10, 119.85]]
```

MATRIZ TRANSPOSTA

- Matrizes transpostas:** análogas aos vetores transpostos; no caso de matrizes, podemos pensar em uma **rotação** da matriz original.

$$\vec{x} = [7.5 \quad 8.25] \Rightarrow \vec{x}^T = \begin{bmatrix} 7.5 \\ 8.25 \end{bmatrix}$$

$$\vec{x} = [[7.5 \quad 8.25]]_{1 \times 2} \Rightarrow \vec{x}^T = \begin{bmatrix} [7.5] \\ [8.25] \end{bmatrix}_{2 \times 1}$$

$R = \begin{matrix} & \text{n_item_cardapio_1} \\ \text{casal_1} & \begin{bmatrix} 1 & 1 & 2 & 2 & 10 & 127.35 \\ 2 & 2 & 2 & 1 & 10 & 128.10 \\ 2 & 1 & 2 & 2 & 10 & 134.85 \\ 2 & 1 & 2 & 1 & 10 & 119.85 \end{bmatrix} \end{matrix}_{4 \times 6}$
 \Rightarrow
 $R^T = \begin{bmatrix} \begin{bmatrix} 1 & 2 & 2 & 2 \end{bmatrix} \\ \begin{bmatrix} 1 & 2 & 1 & 1 \end{bmatrix} \\ \begin{bmatrix} 2 & 2 & 2 & 2 \end{bmatrix} \\ \begin{bmatrix} 2 & 1 & 2 & 1 \end{bmatrix} \\ \begin{bmatrix} 10 & 10 & 10 & 10 \end{bmatrix} \\ \begin{bmatrix} 127.35 & 128.10 & 134.85 & 119.85 \end{bmatrix} \end{bmatrix}_{6 \times 4}$

MATRIZ SIMÉTRICA, DIAGONAL E IDENTIDADE

- Matriz simétrica:** somente matrizes quadradas, os elementos são “espelhados” em torno da diagonal principal.

$$\begin{bmatrix} 1 & 3 & 2 & 5 \\ 3 & 2 & 8 & 1 \\ 2 & 8 & 6 & 7 \\ 5 & 1 & 7 & 4 \end{bmatrix}$$

$$A = A^T$$

$$\begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & \frac{1}{2} & 0 & 0 \\ 0 & 0 & \frac{1}{6} & 0 \\ 0 & 0 & 0 & \frac{1}{4} \end{bmatrix}$$

- Matriz diagonal:** caso especial da matriz simétrica, todos os valores fora da diagonal principal são 0.

$$\begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 2 & 0 & 0 \\ 0 & 0 & 6 & 0 \\ 0 & 0 & 0 & 4 \end{bmatrix}$$

$$\text{diag}(\vec{a})$$

$$\text{diag}(\vec{a}) \times B = \text{diag}(\vec{a}) \odot B$$

$$\text{diag}(\vec{a})^{-1} = \text{diag}([a_1^{-1}, \dots, a_n^{-1}])$$

- Matriz identidade:** caso especial da matriz diagonal, a diagonal principal é igual a 1.

$$\begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}$$

$$I_n (I_4)$$

$$I \times A = A$$

$$(1 \times n = n)$$

MATRIZ INVERSA

- **Matriz inversa:** matriz que, se multiplicada pela matriz original (que deve ser quadrada), resulta na matriz identidade.
- Matrizes *singulares* não têm inversa.
- **Matriz pseudoinversa de Moore-Penrose:** permite calcular a matriz “pseudo” inversa de matrizes retangulares ou singulares.

$$A^{-1}A = I$$

$$(n^{-1}n = 1)$$

$$\begin{bmatrix} [1, 3, 2, 5], \\ [3, 2, 8, 1], \\ [2, 6, 4, 10], \\ [5, 1, 7, 4] \end{bmatrix} \times 2 \text{ dependente}$$

DETERMINANTES

- Determinante:** representação escalar da matriz (quadrada)

$$A = \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix} \rightarrow \det(A) = |A| = a_{11} \cdot a_{22} - a_{12} \cdot a_{21}$$

$$A = \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix} \xrightarrow{\text{pivô}} |A| = a_{11} \cdot C_{11} + a_{12} \cdot C_{12} + a_{13} \cdot C_{13}$$

$$C_{ij} = (-1)^{i+j} \times M_{ij}$$

$$\begin{aligned} C_{11} &= (-1)^{1+1} \times M_{11} \\ C_{11} &= (-1)^2 \times \begin{vmatrix} a_{22} & a_{23} \\ a_{32} & a_{33} \end{vmatrix} \\ C_{11} &= + \begin{vmatrix} a_{22} & a_{23} \\ a_{32} & a_{33} \end{vmatrix} \end{aligned}$$

$$\begin{aligned} C_{12} &= (-1)^{1+2} \times M_{12} \\ C_{12} &= (-1)^3 \times \begin{vmatrix} a_{21} & a_{23} \\ a_{31} & a_{33} \end{vmatrix} \\ C_{12} &= - \begin{vmatrix} a_{21} & a_{23} \\ a_{31} & a_{33} \end{vmatrix} \end{aligned}$$

$$\begin{aligned} C_{13} &= (-1)^{1+3} \times M_{13} \\ C_{13} &= (-1)^4 \times \begin{vmatrix} a_{21} & a_{22} \\ a_{31} & a_{32} \end{vmatrix} \\ C_{13} &= + \begin{vmatrix} a_{21} & a_{22} \\ a_{31} & a_{32} \end{vmatrix} \end{aligned}$$

DETERMINANTES

$$C = \begin{bmatrix} C_{11} & C_{12} & C_{13} \\ C_{21} & C_{22} & C_{23} \\ C_{31} & C_{32} & C_{33} \end{bmatrix} \rightarrow C^T = \text{adj}(A)$$


$$A^{-1} = \frac{1}{\det(A)} \text{adj}(A)$$

O determinante de matrizes singulares é zero

$$\det(A^{-1}) = \frac{1}{\det(A)}$$

MATRIZ ORTOGONAL

- **Matrizes ortogonais:** matrizes onde os vetores que representam as linhas, ou os vetores que representam as colunas, são todos ortonormais (ou seja, ortogonais e unitários).



$$A^T A = A A^T = I$$

$$A^T = A^{-1} I = A^{-1}$$

$$\begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}, \quad \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$$

ÁLGEBRA LINEAR

Operações

OPERAÇÕES COM ESCALARES

- A operação é “transmitida” (*broadcasted*) para todos os elementos

$$\begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} + 4 = \begin{bmatrix} 5 \\ 6 \\ 7 \end{bmatrix}$$

$$\begin{bmatrix} 9 & 8 & 7 \\ 6 & 5 & 4 \\ 3 & 2 & 1 \end{bmatrix} - 5 = \begin{bmatrix} 4 & 3 & 2 \\ 1 & 0 & -1 \\ -2 & -3 & -4 \end{bmatrix}$$

$$\begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{bmatrix} \times 2 = \begin{bmatrix} 2 & 4 & 6 \\ 8 & 10 & 12 \\ 14 & 16 & 18 \end{bmatrix}$$

$$\begin{bmatrix} 8 \\ 10 \\ 12 \end{bmatrix} \div 2 = \begin{bmatrix} 4 \\ 5 \\ 6 \end{bmatrix}$$

OPERAÇÕES DENTRO DE TENSORES

Redução

Operações

- Representação “reduzida” do tensor original.
- A operação pode ser realizada ao longo de uma dimensão (axis) ou do tensor inteiro.

$$\text{sum} \left(\begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} \right) = 6$$

$$\text{sum} \left(\begin{bmatrix} 9 & 8 & 7 \\ 6 & 5 & 4 \\ 3 & 2 & 1 \end{bmatrix} \right) = 45$$

$$\text{sum} \left(\begin{bmatrix} 9 & 8 & 7 \\ 6 & 5 & 4 \\ 3 & 2 & 1 \end{bmatrix}, \text{axis} = 0 \right) = [18 \quad 15 \quad 12]$$

Algumas funções comuns:
sum, mean, prod, min, max

$$\text{sum} \left(\begin{bmatrix} 9 & 8 & 7 \\ 6 & 5 & 4 \\ 3 & 2 & 1 \end{bmatrix}, \text{axis} = 1 \right) = \begin{bmatrix} 24 \\ 15 \\ 6 \end{bmatrix}$$

OPERAÇÕES ENTRE TENSORES (elemento a elemento)

- Os tensores devem ter o mesmo número de dimensões (shape).
- Resultado mantém o mesmo formato.

$$\begin{bmatrix} 2 \\ 1 \\ 0 \end{bmatrix} + \begin{bmatrix} 3 \\ 4 \\ 5 \end{bmatrix} = \begin{bmatrix} 5 \\ 5 \\ 5 \end{bmatrix}$$

$$\begin{bmatrix} 9 & 8 \\ 7 & 6 \\ 5 & 4 \end{bmatrix} - \begin{bmatrix} 1 & 2 \\ 3 & 4 \\ 5 & 6 \end{bmatrix} = \begin{bmatrix} 8 & 6 \\ 4 & 2 \\ 0 & -2 \end{bmatrix}$$

$$\begin{bmatrix} 1 & 3 \\ 4 & 6 \\ 7 & 9 \end{bmatrix} \odot \begin{bmatrix} 2 & 2 \\ 3 & 3 \\ 4 & 4 \end{bmatrix} = \begin{bmatrix} 2 & 6 \\ 12 & 18 \\ 28 & 36 \end{bmatrix}$$

produto Hadamard

$$\begin{bmatrix} 10 \\ 9 \\ 8 \end{bmatrix} \div \begin{bmatrix} 2 \\ 3 \\ 4 \end{bmatrix} = \begin{bmatrix} 5 \\ 3 \\ 2 \end{bmatrix}$$



$$\begin{bmatrix} 10 \\ 9 \\ 8 \end{bmatrix} \odot \begin{bmatrix} 1/2 \\ 1/3 \\ 1/4 \end{bmatrix} = \begin{bmatrix} 5 \\ 3 \\ 2 \end{bmatrix}$$



OPERAÇÕES ENTRE TENSORES (elemento a elemento)

- Soma/subtração entre vetores tem um significado espacial.

$$\begin{bmatrix} 2 \\ 1 \\ 0 \end{bmatrix} + \begin{bmatrix} 3 \\ 4 \\ 5 \end{bmatrix} = \begin{bmatrix} 5 \\ 5 \\ 5 \end{bmatrix}$$



$$\begin{bmatrix} 3 \\ 4 \\ 5 \end{bmatrix} + \begin{bmatrix} 2 \\ 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 5 \\ 5 \\ 5 \end{bmatrix}$$





OPERAÇÕES ENTRE TENSORES (elemento a elemento)

- Soma/subtração entre vetores tem um significado espacial.

$$\begin{bmatrix} 3 \\ 4 \\ 5 \end{bmatrix} - \begin{bmatrix} 2 \\ 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 1 \\ 3 \\ 5 \end{bmatrix}$$

$$\begin{bmatrix} 3 \\ 4 \\ 5 \end{bmatrix} + \begin{bmatrix} -2 \\ -1 \\ 0 \end{bmatrix} = \begin{bmatrix} -2 \\ -1 \\ 0 \end{bmatrix} + \begin{bmatrix} 3 \\ 4 \\ 5 \end{bmatrix} = \begin{bmatrix} 1 \\ 3 \\ 5 \end{bmatrix}$$



OPERAÇÕES ENTRE TENSORES

Multiplicação matricial

- Diferente da multiplicação elemento-a-elemento (produto Hadamard).
- Deve haver compatibilidade no número de dimensões (shape).
- Não é comutativa: $A \times B \neq B \times A$

$$\begin{bmatrix} 1 & 3 \\ 4 & 6 \\ 7 & 9 \end{bmatrix} \odot \begin{bmatrix} 2 & 2 \\ 3 & 3 \\ 4 & 4 \end{bmatrix} = \begin{bmatrix} 2 & 6 \\ 12 & 18 \\ 28 & 36 \end{bmatrix}$$

$$\begin{bmatrix} 1 & 3 \\ 4 & 6 \\ 7 & 9 \end{bmatrix}_{3 \times 2} \times \begin{bmatrix} 2 & 2 \\ 3 & 3 \\ 4 & 4 \end{bmatrix}_{3 \times 2} = \text{❌}$$

$$\begin{bmatrix} 1 & 3 \\ 4 & 6 \\ 7 & 9 \end{bmatrix}_{3 \times 2} \times \begin{bmatrix} 2 & 3 & 4 \\ 2 & 3 & 4 \end{bmatrix}_{2 \times 3} = \text{✅}$$

OPERAÇÕES ENTRE TENSORES

Multiplicação matricial

$$\begin{bmatrix} 1 & 3 \\ 4 & 6 \\ 7 & 9 \end{bmatrix}_{3 \times 2} \times \begin{bmatrix} 2 & 3 & 4 \\ 2 & 3 & 4 \end{bmatrix}_{2 \times 3} =$$


$$\begin{bmatrix} 1 * 2 + 3 * 2 & 1 * 3 + 3 * 3 & 1 * 4 + 3 * 4 \\ 4 * 2 + 6 * 2 & 4 * 3 + 6 * 3 & 4 * 4 + 6 * 4 \\ 7 * 2 + 9 * 2 & 7 * 3 + 9 * 3 & 7 * 4 + 9 * 4 \end{bmatrix}_{3 \times 3} =$$

$$\begin{bmatrix} 8_{11} & 12_{12} & 16_{13} \\ 20_{21} & 30_{22} & 40_{23} \\ 32_{31} & 48_{32} & 64_{33} \end{bmatrix}_{3 \times 3}$$

Produto vetorial/escalar/interno – *dot product*

- Multiplicação elemento-a-elemento seguida de redução por soma
- Resultado é um escalar

$$\begin{bmatrix} 2 \\ 1 \\ 0 \end{bmatrix} \cdot \begin{bmatrix} 3 \\ 4 \\ 5 \end{bmatrix} = 2 * 3 + 1 * 4 + 0 * 5 = 10$$




$$\begin{bmatrix} 2 & 1 & 0 \end{bmatrix}_{1 \times 3} \times \begin{bmatrix} 3 \\ 4 \\ 5 \end{bmatrix}_{3 \times 1} = [2 * 3 + 1 * 4 + 0 * 5]_{1 \times 1} = 10$$

$$\vec{x} \cdot \vec{x} = \|\vec{x}\|^2$$


OPERAÇÕES ENTRE TENSORES

Regra de cosseno

Operações



$$c^2 = a^2 + b^2 - 2ab \cos \theta$$



$$\vec{b} = \vec{a} + \vec{c} \quad \rightarrow \quad \vec{c} = \vec{b} - \vec{a}$$




$$\cos \theta = \frac{\vec{a} \cdot \vec{b}}{ab}$$

ÁLGEBRA LINEAR

Transformações

TRANSFORMAÇÕES AFINS


- É possível “transformar” um vetor através da manipulação do espaço cartesiano.




TRANSFORMAÇÕES AFINS

- Um vetor pode ser **transformado** em outro através da “aplicação” de uma matriz.
- A e B são chamadas matrizes de *espelhamento*.


$$A \times \begin{bmatrix} 1 \\ 2 \end{bmatrix} = \begin{bmatrix} -1 \\ 2 \end{bmatrix}$$



$$B \times \begin{bmatrix} 1 \\ 2 \end{bmatrix} = \begin{bmatrix} 1 \\ -2 \end{bmatrix}$$




$$B \times \begin{bmatrix} 3 \\ 4 \end{bmatrix} = \begin{bmatrix} 3 \\ -4 \end{bmatrix}$$




TRANSFORMAÇÕES AFINS

- Outras transformações afins:


escalonamento



cisalhamento



rotação





$$\begin{bmatrix} 3 & 0 \\ 0 & 2 \end{bmatrix} \times \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 3 \\ 2 \end{bmatrix} \quad \begin{bmatrix} -1 & 0 \\ 0 & 2 \end{bmatrix} \times \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} -1 \\ 2 \end{bmatrix} \quad \begin{bmatrix} -2 & 0 \\ 0 & -5 \end{bmatrix} \times \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} -2 \\ -5 \end{bmatrix}$$

$$\begin{bmatrix} 3 & 5 \\ 1 & -2 \end{bmatrix} \times \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 3 \\ 1 \end{bmatrix} \quad \begin{bmatrix} 3 & 5 \\ 1 & -2 \end{bmatrix} \times \begin{bmatrix} 0 \\ 1 \end{bmatrix} = \begin{bmatrix} 5 \\ -2 \end{bmatrix}$$


\hat{i} \hat{j}

TRANSFORMAÇÕES E DETERMINANTES


$$A = \begin{bmatrix} a & b \\ c & d \end{bmatrix} \rightarrow \det(A) = |A| = ad - bc$$



Área




Área $\times \det(A)$



Matrizes singulares
 $\det(A) = 0$

TRANSFORMAÇÕES E MATRIZES INVERSAS



$$A \times A^{-1} = I$$

TRANSFORMAÇÕES E SISTEMAS LINEARES

$$\begin{cases} 127.35 = x_1 + x_2 + 2x_3 + 2x_4 + 10 \\ 128.10 = 2x_1 + 2x_2 + 2x_3 + x_4 + 10 \\ 134.85 = 2x_1 + x_2 + 2x_3 + 2x_4 + 10 \\ 119.85 = 2x_1 + x_2 + 2x_3 + x_4 + 10 \end{cases} \rightarrow \begin{bmatrix} 127.35 \\ 128.10 \\ 134.85 \\ 119.85 \end{bmatrix} = \begin{bmatrix} 1 & 1 & 2 & 2 \\ 2 & 2 & 2 & 1 \\ 2 & 1 & 2 & 2 \\ 2 & 1 & 2 & 1 \end{bmatrix} \times \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} + \begin{bmatrix} 10 \\ 10 \\ 10 \\ 10 \end{bmatrix}$$

$$\begin{bmatrix} 1 & 1 & 2 & 2 \\ 2 & 2 & 2 & 1 \\ 2 & 1 & 2 & 2 \\ 2 & 1 & 2 & 1 \end{bmatrix} \times \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} = \begin{bmatrix} 127.35 \\ 128.10 \\ 134.85 \\ 119.85 \end{bmatrix} - \begin{bmatrix} 10 \\ 10 \\ 10 \\ 10 \end{bmatrix}$$

$$\begin{bmatrix} 1 & 1 & 2 & 2 \\ 2 & 2 & 2 & 1 \\ 2 & 1 & 2 & 2 \\ 2 & 1 & 2 & 1 \end{bmatrix} \times \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} = \begin{bmatrix} 117.35 \\ 118.10 \\ 124.85 \\ 109.85 \end{bmatrix}$$

$$A \times \vec{x} = \vec{y}$$


EIGENVECTORS E EIGENVALUES

- **Eigen** (alemão): típico, característico, “auto”
- **Eigenvectors**: vetores que, após uma transformação, mudam de direção
- **Eigenvalues (λ)**: valores escalares aplicados a


$$A\vec{v} = \lambda\vec{v}$$

Matrizes singulares


$\begin{bmatrix} 1, & 3, & 2, & 5 \\ 3, & 2, & 8, & 1 \\ 2, & 6, & 4, & 10 \\ 5, & 1, & 7, & 4 \end{bmatrix}$




eigenvalue = 1



eigenvalue = 1,5




eigenvalue = -1



eigenvalue = 0

EIGENVECTORS E EIGENVALUES

- Matriz de transformação A_n pode ter vários eigenvectors.
- Mas no máximo n eigenvectors (se A for simétrica) serão linearmente independentes (ortogonais).
- Esses eigenvectors são expressos com tamanho 1 (ortonormais), junto com seus respectivos eigenvalues λ .



$$A\vec{v} = \lambda\vec{v}$$

$$\det(A_n) = \prod_{i=1}^n \lambda_i$$

Matriz simétrica: somente matrizes quadradas, os elementos são “espelhados” em torno da diagonal principal.

$$\begin{bmatrix} 1 & 3 & 2 & 5 \\ 3 & 2 & 8 & 1 \\ 2 & 8 & 6 & 7 \\ 5 & 1 & 7 & 4 \end{bmatrix}$$

$$A = A^T$$

AUTODECOMPOSIÇÃO (EIGENDECOMPOSITION)

$$A = Q\Lambda Q^{-1}$$

$$A_n \quad Q = \begin{bmatrix} \overrightarrow{v_1} & \overrightarrow{v_2} & \cdots & \overrightarrow{v_n} \\ q_{11} & q_{12} & \cdots & q_{1n} \\ q_{21} & q_{22} & \cdots & q_{2n} \\ \vdots & \cdots & \ddots & \vdots \\ q_{n1} & q_{n2} & \cdots & q_{nn} \end{bmatrix} \quad \Lambda = \begin{bmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \cdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_n \end{bmatrix}$$

$|\lambda_1| > |\lambda_2| > \cdots > |\lambda_n|$

Se A é uma matriz simétrica, então: $A = Q\Lambda Q^T$

DECOMPOSIÇÃO DE VALOR SINGULAR (SINGULAR VALUE DECOMPOSITION - SVD)

Transformações

$$A = UDV^T$$

$A_{m \times n}$

$U = \begin{bmatrix} \overrightarrow{u_1} & \overrightarrow{u_2} & \cdots & \overrightarrow{u_m} \end{bmatrix}_{m \times m}$

$\overrightarrow{u_1} \quad \overrightarrow{u_2} \quad \cdots \quad \overrightarrow{u_m} \rightarrow \text{eigenvectors de } AA^T$

$D = \begin{bmatrix} s_1 & 0 & \cdots & 0 \\ 0 & s_2 & \cdots & 0 \\ \vdots & \cdots & \ddots & \vdots \\ 0 & 0 & \cdots & s_m \end{bmatrix}_{m \times n}$

$\sqrt{\lambda_{AA^T}} = \sqrt{\lambda_{A^T A}}$

$s_1 > s_2 > \cdots > s_m$

$V = \begin{bmatrix} \overrightarrow{v_1} & \overrightarrow{v_2} & \cdots & \overrightarrow{v_n} \end{bmatrix}_{n \times n}$


$\overrightarrow{v_1} \quad \overrightarrow{v_2} \quad \cdots \quad \overrightarrow{v_n} \rightarrow \text{eigenvectors de } A^T A$

$$A^+ = U D^+ V^T$$

$$D^+ = \left(\frac{1}{D^*}\right)^T = D^{-1}$$

ANÁLISE DO COMPONENTE PRINCIPAL (*PRINCIPAL COMPONENT ANALYSIS – PCA*)



Transformações



ANÁLISE DO COMPONENTE PRINCIPAL (PRINCIPAL COMPONENT ANALYSIS – PCA)

Transformações

Transformação que provoca rotação e translação dos eixos, de forma a remover as correlações, equilibrar os valores das variáveis em volta da origem do sistema, e acumular a variância nos primeiros eixos.



ÁLGEBRA LINEAR

Aplicações

Sistemas lineares

- Podem ser representados como operações matriciais:

$$\begin{cases} 127.35 = x_1 + x_2 + 2x_3 + 2x_4 + 10 \\ 128.10 = 2x_1 + 2x_2 + 2x_3 + x_4 + 10 \\ 134.85 = 2x_1 + x_2 + 2x_3 + 2x_4 + 10 \\ 119.85 = 2x_1 + x_2 + 2x_3 + x_4 + 10 \end{cases} \rightarrow \text{sistema linear}$$

$$\begin{bmatrix} 127.35 \\ 128.10 \\ 134.85 \\ 119.85 \end{bmatrix}_{4 \times 1} = \begin{bmatrix} 1 & 1 & 2 & 2 \\ 2 & 2 & 2 & 1 \\ 2 & 1 & 2 & 2 \\ 2 & 1 & 2 & 1 \end{bmatrix}_{4 \times 4} \times \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix}_{4 \times 1} + \begin{bmatrix} 10 \\ 10 \\ 10 \\ 10 \end{bmatrix}_{4 \times 1} \rightarrow \boxed{y = Ax + b}$$


$$\begin{bmatrix} 127.35 \\ 128.10 \\ 134.85 \\ 119.85 \end{bmatrix}_{4 \times 1} = \begin{bmatrix} 1 & 1 & 1 & 2 & 2 \\ 1 & 2 & 2 & 2 & 1 \\ 1 & 2 & 1 & 2 & 2 \\ 1 & 2 & 1 & 2 & 1 \end{bmatrix}_{4 \times 5} \times \begin{bmatrix} 10 \\ x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix}_{5 \times 1} \rightarrow \boxed{y = Ax}$$

(Note: A callout bubble with $m \geq n$ points to the coefficient matrix in the second equation.)

(Note: The vector $\begin{bmatrix} 10 \\ x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix}$ is labeled (x_0) in the original image.)

$$\begin{aligned} y &= Ax \\ A^{-1}y &= A^{-1}Ax \\ A^{-1}y &= Ix \rightarrow A^+ \\ x &= \boxed{A^{-1}}y \end{aligned}$$

Redes neurais



y (variável alvo, y_{true})

batch

$$\begin{bmatrix} 127.35 \\ 128.10 \\ 134.85 \\ 119.85 \end{bmatrix}_{4 \times 1} = \begin{bmatrix} 1 & 1 & 1 & 2 & 2 \\ 1 & 2 & 2 & 2 & 1 \\ 1 & 2 & 1 & 2 & 2 \\ 1 & 2 & 1 & 2 & 1 \end{bmatrix}_{4 \times 5} \times \begin{bmatrix} x_0 \\ x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix}_{5 \times 1}$$

X (variáveis preditoras)

REDE NEURAL

$$\begin{bmatrix} 1 & 1 & 1 & 2 & 2 \\ 1 & 2 & 2 & 2 & 1 \\ 1 & 2 & 1 & 2 & 2 \\ 1 & 2 & 1 & 2 & 1 \end{bmatrix}_{4 \times 5} \times \begin{bmatrix} w_{11} & w_{12} & w_{13} & w_{14} \\ w_{21} & w_{22} & w_{23} & w_{24} \\ w_{31} & w_{32} & w_{33} & w_{34} \\ w_{41} & w_{42} & w_{43} & w_{44} \\ w_{51} & w_{52} & w_{53} & w_{54} \end{bmatrix}_{5 \times 4} + [b_1 \ b_2 \ b_3 \ b_4]_{1 \times 4}$$

(broadcasting)

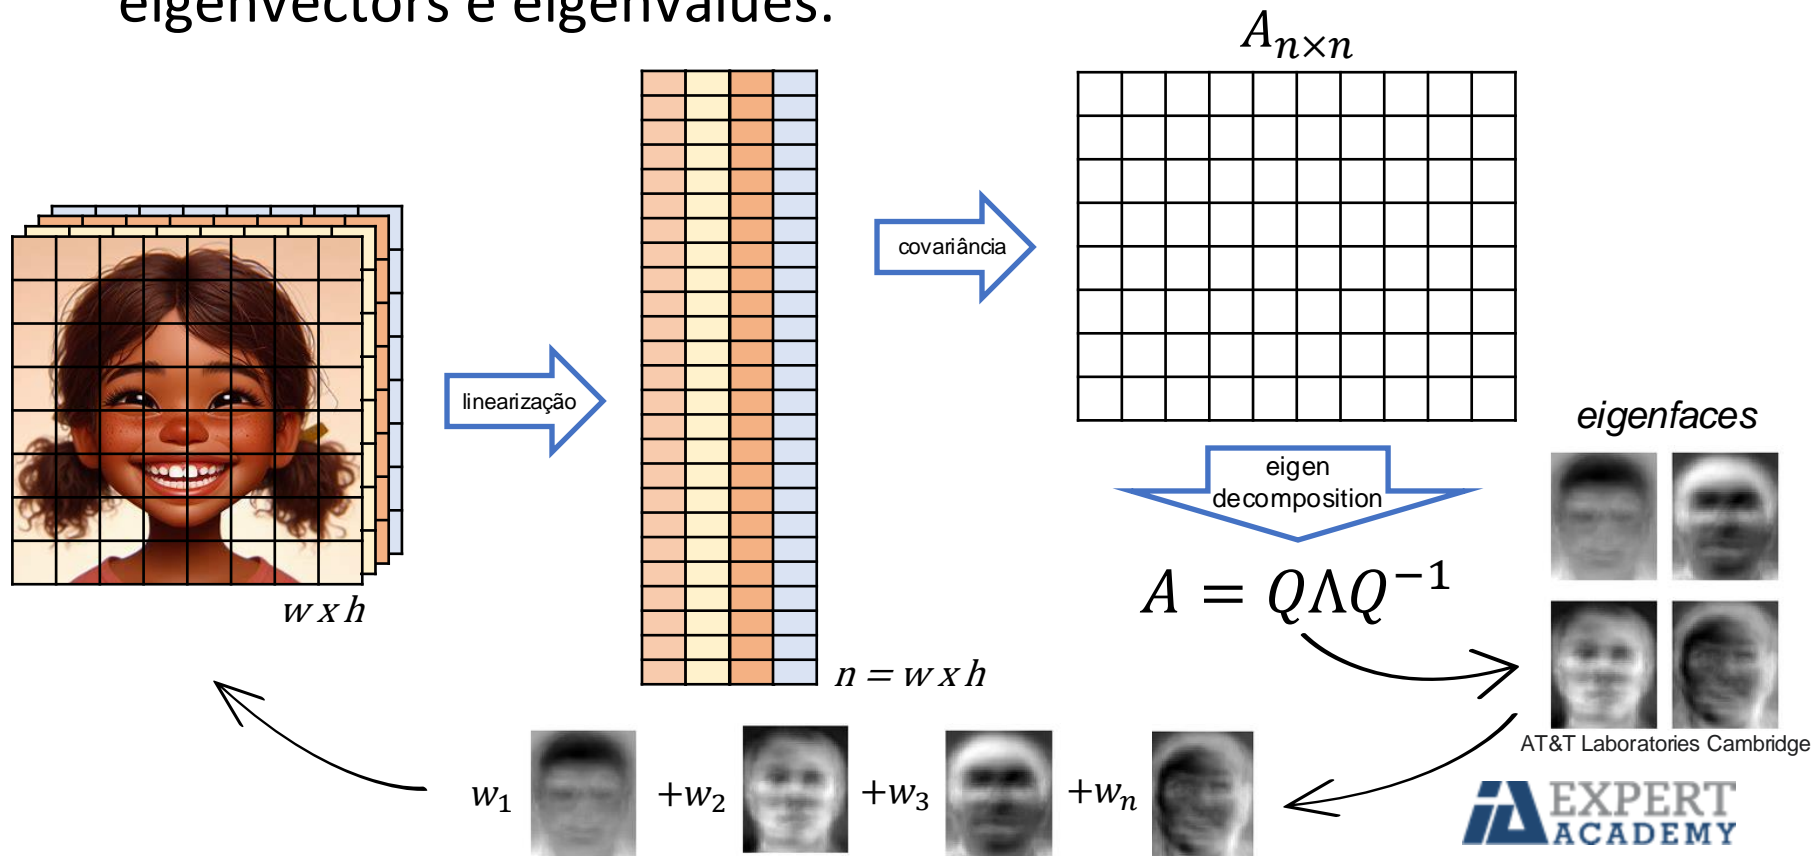
$$R_{4 \times 4} \times W_{4 \times 1} + b_{1(4) \times 1} = O_{4 \times 1}$$

y_{pred}

$$\begin{bmatrix} b_1 & b_2 & b_3 & b_4 \\ b_1 & b_2 & b_3 & b_4 \\ b_1 & b_2 & b_3 & b_4 \\ b_1 & b_2 & b_3 & b_4 \end{bmatrix}_{4 \times 4}$$

Eigendecomposition

- Um dataset qualquer pode ser decomposto em seus eigenvectors e eigenvalues.



Singular value decomposition

- Comprimir dados



$w \times h$

decomposição

$$A_{w \times h}$$

=

$$U_{w \times w} D_{w \times h} V_{h \times h}^T$$

reconstrução


quantidade de
informação necessária
para armazenar a
matriz

$$s_1 > s_2 > \dots > s_m$$

$$U_{w \times 1} D_{1 \times 1} V_{h \times 1}^T$$



$$U_{w \times 3} D_{3 \times 3} V_{h \times 3}^T$$



$$U_{w \times 8} D_{8 \times 8} V_{h \times 8}^T$$






$w = h = 200$
 $40000 \Rightarrow 3208$
(-92%)

$$\left\{ \begin{array}{l} w \times 8 \\ + \\ 8 \\ + \\ h \times 8 \end{array} \right.$$



PCA

- Redução de dimensionalidade e visualização.



Semelhança entre dados não-estruturados

- Similaridade de cosseno entre embeddings



$$\theta = 0$$
$$\cos \theta = 1$$

$$\cos \theta = \frac{\vec{a} \cdot \vec{b}}{ab}$$